

## **TEMA 1**

### ***Utilizarea metodei ACP pentru reducerea dimensionalității datelor***

Analiza a fost realizata pe un set de date ce contine informatii despre 200 de companii listate la bursa, obtinute din sursa Yahoo Finance, sectiunea Financials (Income Statement & Cash Flow). Datele se refera la TTM (Trailing Twelve Months), oferind o privire de ansamblu asupra performantei financiare a acestor companii pe parcursul ultimelor 12 luni.

In ceea ce priveste structura setului de date, acesta nu prezinta valori lipsa, iar variabilele au fost notate de la X1 la X10, cu denumiri sugestive in fisierul Excel. In privinta outlierilor, acestia sunt prezenti intr-un numar considerabil in setul de date, insa am decis sa ii pastrez in analiza, deoarece reprezinta companii cu performante financiare solide, iar pastrarea lor ma va ajuta sa identific liderii pietei si companiile cu potential investitional.

Setul de date este compus din urmatoarele variabile, notate de la X1 la X10 si exprimate in mii USD (\$):

- **Total Revenue/Venit total** – ce reprezinta suma totală a veniturilor generate de o companie din vânzarea bunurilor sau serviciilor sale, fără a ține cont de costurile asociate.
- **Gross Profit/Profitul brut** – este calculat prin scăderea costurilor directe asociate producției bunurilor sau serviciilor din venitul total si reflectă eficiența în generarea profitului din activitatea principală.
- **Operating Income/Venitul operational** – este venitul generat din activitățile de bază ale companiei, excluzând veniturile și cheltuielile non-operaționale; acesta indica profitabilitatea operațiunilor zilnice ale companiei.
- **Net Income/ Venitul net** - reprezintă profitul total obținut de companie după scăderea tuturor cheltuielilor, inclusiv taxe și cheltuieli non-operaționale; este un indicator esențial al sănătății financiare a unei companii.
- **Earnings before interest and taxes (EBIT)** - acest indicator arată profitul companiei înainte de deducerea cheltuielilor cu dobânzile și impozitele, fiind util pentru compararea performanței între companii, indiferent de structura lor de capital.
- **Earnings per share (EPS)** - reprezintă venitul pe acțiune și oferă o măsură a profitabilității unei companii pe acțiune.
- **Operating Cash Flow/Fluxul de numerar operational** - acesta măsoară capacitatea companiei de a genera numerar din activitățile sale operaționale.
- **Investing Cash Flow/Fluxul de numerar din activitati de investitii** - reflectă numerarul cheltuit sau generat din activitățile de investiții ale companiei, inclusiv achiziții de active sau vânzări de active.

- **Financing Cash Flow/Fluxul de numerar din activitati de finantare** - acesta arată fluxurile de numerar rezultate din activitățile de finanțare, cum ar fi emisiunea de acțiuni, împrumuturile și rambursările de datorii.

- **Free Cash Flow/Fluxul de numerar liber** - este un indicator important al capacității unei companii de a genera numerar după ce a acoperit toate cheltuielile necesare.

În ceea ce privește observațiile, fiecare linie din setul de date corespunde unei companii listate la bursă, oferind o imagine de ansamblu asupra performanței financiare a acestora prin intermediul variabilelor de mai sus. Aceasta permite compararea companiilor în funcție de diferiți indicatori financiari.

Obiectivul general al analizei este de a evalua și de a înțelege performanța financiară a companiilor listate la bursă și de a identifica companiile cu cel mai mare potențial investitional. Acesta se realizează printr-o analiză statistică detaliată a variabilelor financiare, folosind tehnici precum analiza componentelor principale (PCA) pentru a înțelege mai bine relațiile dintre variabile și modul în care acestea contribuie la succesul financiar al firmelor. Analiza urmărește să evidențieze factorii care au o influență semnificativă asupra performanței și să ofere o imagine clară asupra companiilor care ar putea reprezenta oportunități viabile pentru investiții. Astfel, scopul este de a sprijini deciziile investiționale prin identificarea liderilor de piață și a firmelor care prezintă o stabilitate și o creștere financiară promițătoare.

### ***Interpretarea indicatorilor statistici***

```
> summary(temal)
Companie      X1      X2      X3      X4
Length:200    Min.    : -2061000  Min.    : -5880000  Min.    : -11769000
Class :character 1st Qu.:  2562563  1st Qu.:  1131095  1st Qu.:  183192   1st Qu.:   16376
Mode  :character Median :  7546600  Median :  2948198  Median :  802128   Median :   427586
                Mean  :  36770656  Mean  :  14453219  Mean  :  6230998   Mean  :  4492233
                3rd Qu.:  26031775  3rd Qu.:  10949250  3rd Qu.:  3415500   3rd Qu.:  2408771
                Max.   :  665035000  Max.   :  188261000  Max.   :  120594000  Max.   :  101956000

                X5      X6      X7      X8      X9
Min.    : -13737000  Min.    : -47.340  Min.    : -5511000  Min.    : -96970000  Min.    : -120188000
1st Qu.:   88130    1st Qu.: -0.005  1st Qu.:   318581  1st Qu.: -2008607  1st Qu.: -1862750
Median :   731052    Median :   2.010  Median :   972150  Median :  -423876   Median :  -333922
Mean   :   5970001    Mean :   2.873  Mean   :   7461674  Mean   : -3644732   Mean   : -3784671
3rd Qu.:  3524250    3rd Qu.:   4.820  3rd Qu.:  5626500  3rd Qu.:  -82646   3rd Qu.:   2500
Max.   :  123962000  Max.   :  27.600  Max.   :  118548000  Max.   :   5510000  Max.   :  15861000

                X10
Min.    : -12584000
1st Qu.:   116478
Median :   547864
Mean   :   4470735
3rd Qu.:  2877500
Max.   :  104339000
```

Figura 1. Rezultatul comenzii summary

```
> describe(temal[-1])
```

	vars	n	mean	sd	median	trimmed	mad	min	max
X1	1	200	36770656.25	86281249.16	7546600.00	15915770.82	9314438.95	4.13100e+03	665035000.0
X2	2	200	14453219.43	32157524.38	2948198.50	6425775.54	3441437.07	-2.06100e+06	188261000.0
X3	3	200	6230997.80	17885128.88	802128.50	2128041.04	1253326.29	-5.88000e+06	120594000.0
X4	4	200	4492233.11	15127218.03	427586.00	1386796.71	957887.10	-1.17690e+07	101956000.0
X5	5	200	5970001.40	18380522.59	731052.50	2025606.26	1367297.46	-1.37370e+07	123962000.0
X6	6	200	2.87	6.92	2.01	2.63	3.31	-4.73400e+01	27.6
X7	7	200	7461674.04	19967399.83	972150.00	2648941.59	1353052.64	-5.51100e+06	118548000.0
X8	8	200	-3644732.08	11461551.85	-423876.50	-1176700.08	604435.26	-9.69700e+07	5510000.0
X9	9	200	-3784671.39	14574789.95	-333922.00	-1092178.14	801778.96	-1.20188e+08	15861000.0
X10	10	200	4470735.44	14055973.44	547864.50	1558218.74	877573.92	-1.25840e+07	104339000.0

	range	skew	kurtosis	se
X1	665030869.00	4.56	24.57	6101005.64
X2	190322000.00	3.75	14.67	2273880.36
X3	126474000.00	4.72	24.05	1264669.59
X4	113725000.00	4.89	25.22	1069655.84
X5	137699000.00	4.78	24.51	1299699.22
X6	74.94	-1.44	14.59	0.49
X7	124059000.00	4.21	18.05	1411908.38
X8	102480000.00	-5.80	39.20	810454.10
X9	136049000.00	-6.07	41.95	1030593.28
X10	116923000.00	5.03	28.42	993907.41

Figura 2. Rezultatul comenzii describe

**Variabila X1**, *venitul total*, prezintă o distribuție largă, între 4,131 USD și 665,035,000 USD, indicând diferențe mari între companiile analizate, de la cele mici la gigantul pieței. Majoritatea companiilor au venituri între 2,5 milioane și 26 milioane USD, dar media de 36,77 milioane USD este influențată de câteva companii foarte mari. Mediana de 7,5 milioane USD, mai mică decât media, arată o distribuție asimetrică, cu câteva companii extrem de profitabile. Kurtosis-ul de 24.57 sugerează o concentrație mare de companii în jurul medianei și câteva valori extreme, evidențiind o piață diversificată și dominată de câțiva jucători mari.

**Variabila X2**, *profitul brut*, prezintă o distribuție cu valori între -2,061,000 USD și 188,261,000 USD, indicând o variație semnificativă între companiile analizate, de la profituri negative la profituri foarte mari. Majoritatea companiilor au profituri între 1,13 milioane și 10,95 milioane USD, dar media de 14,45 milioane USD este influențată de câteva companii extrem de profitabile. Mediana de 2,95 milioane USD și skewness-ul de 3,75 sugerează o asimetrie puternică spre dreapta, ceea ce înseamnă că majoritatea companiilor au profituri mai mici, dar există câțiva jucători mari care determină o medie mult mai mare. Kurtosis-ul de 14,67 indică o distribuție leptocurtică, concentrată în jurul medianei, dar cu câteva valori extreme foarte mari, ceea ce confirmă că piața este dominată de câțiva actori majori cu profituri semnificative, iar restul companiilor au profituri mult mai mici.

**Variabila X3**, *venitul operațional*, prezintă o distribuție semnificativ variabilă, cu valori între -5,880,000 USD și 120,594,000 USD, ceea ce indică o gamă largă de performanțe între companiile analizate, de la pierderi semnificative până la profituri operaționale mari. 50% dintre valorile veniturilor operaționale sunt între 183,192 USD și 3,415,500 USD, ceea ce este semnificativ mai mic decât valoarea medie de 7,055,975 USD, care este influențată de câteva companii cu venituri operaționale foarte mari. Mediana de 802,128 USD fiind mult mai mică decât media confirmă o asimetrie puternică spre dreapta, ceea ce înseamnă că majoritatea companiilor au venituri operaționale mai mici, dar există câțiva jucători mari care generează venituri mult mai mari. Skewness-ul de 4.72 subliniază această tendință de distribuție asimetrică. Kurtosis-ul de 24.05 sugerează o distribuție leptocurtică, indicând o concentrație mare de valori în jurul medianei, dar cu câteva valori extreme, ce reflectă performanțele excepționale ale

companiilor dominante. Analiza sugerează o piață diversă, unde majoritatea companiilor au venituri operaționale relativ scăzute, iar câțiva jucători mari sunt responsabili pentru majoritatea valorilor extreme.

În ceea ce privește **variabila X4**, reprezentată de *venitul net*, valoarea medie în perioada analizată este de 4.492.233 USD, având un minim de -11.769.000 USD și un maxim de 101.956.000 USD, ceea ce sugerează o mare variabilitate între companiile incluse în analiză, de la pierderi semnificative la profituri considerabile. Conform medianei, 50% din observații au venituri nete sub 427.586 USD și 50% depășesc această valoare. Diferența între medie și mediana indică o distribuție asimetrică, cu o concentrație mare de valori mici și câteva valori extreme, care influențează media. Coeficientul de asimetrie de 4.89 subliniază o distribuție puternic asimetrică spre dreapta, iar kurtosis-ul de 25.22 indică o distribuție leptocurtică, cu o concentrație mare în jurul medianei și câteva valori extreme. Abaterea standard ridicată de 15.127.218 USD reflectă variabilitatea mare între veniturile companiilor analizate.

Analizând **variabila X5**, care reprezintă *EBIT (Earnings Before Interest and Taxes)*, observăm o distribuție semnificativ variabilă, cu valori cuprinse între -13,737,000 și 123,962,000, indicând o diferență mare între companiile analizate în ceea ce privește rentabilitatea operațională. Media EBIT-ului este de 5,970,001, în timp ce mediana este mult mai mică, de 731,052, ceea ce sugerează o asimetrie puternică spre dreapta. 50% dintre observațiile din setul de date sunt sub 731,052 și 50% sunt peste această valoare, însă media este mult influențată de câteva companii foarte profitabile. Coeficientul de asimetrie de 4.78 subliniază această tendință, arătând că majoritatea valorilor se concentrează în partea stângă, iar câteva valori extreme, aflate la capătul drept al scalei, trag media în sus. În plus, valoarea kurtosis-ului de 24.51 sugerează o distribuție leptocurtică, adică o concentrație puternică a datelor în jurul medianei și câteva observații extreme care domină analiza. Abaterea standard de 18,380,522.59 indică o dispersie semnificativă a valorilor, ceea ce subliniază volatilitatea acestora între companii. Valorile extreme din analiza sugerează că unele companii sunt mult mai eficiente decât altele în generarea de profit operațional, ceea ce poate indica strategii de afaceri foarte eficiente sau piețe mai favorabile.

**Variabila X6**, reprezentând *venitul pe acțiune (EPS)*, prezintă o distribuție variabilă, cu valori cuprinse între -47.34 și 27.60, majoritatea valorilor fiind concentrate în jurul medianei de 2.010. Coeficientul de asimetrie de -1.44 indică o distribuție asimetrică spre stânga, în care majoritatea valorilor sunt concentrate în partea dreaptă, cu o coadă mai lungă în stânga, ceea ce poate reflecta un număr semnificativ de companii cu pierderi sau valori mici ale EPS. Kurtosis-ul de 14.59 sugerează o distribuție leptocurtică, adică distribuția are o concentrație mare de valori în jurul mediei și câteva valori extreme, ce se îndepărtează de medie. Din punct de vedere economic, acest lucru arată că majoritatea companiilor au un EPS mic sau negativ, dar câteva sunt extrem de profitabile, ceea ce influențează media. Variabilitatea mare sugerează volatilitate pe piață, cu companii care pot experimenta schimbări mari în performanța lor financiară.

**Variabila X7**, *fluxul de numerar operațional*, variază semnificativ, cu valori între -5,511,000 și 118,548,000 USD, reflectând diferențe mari între companii, de la pierderi până la fluxuri mari de numerar. Majoritatea companiilor au fluxuri între 315,881 și 5,626,500 USD, iar

media de 7,461,674 USD este influențată de câțiva jucători cu performanțe remarcabile. Mediana de 972,150 USD sugerează o asimetrie spre dreapta, iar coeficientul de asimetrie de 4.21 și kurtosis-ul de 18.05 indică o distribuție cu coadă lungă spre dreapta și câteva valori extreme. Aceasta sugerează o performanță financiară variabilă între companii, cu câțiva lideri generând fluxuri de numerar semnificativ mai mari decât media.

**Variabila X8**, *fluxul de numerar din activitățile de investiții*, variază semnificativ între -96,970,000 și 5,510,000 USD, cu o medie de -3,644,732 USD și o mediană de -423,876 USD. Coeficientul de asimetrie de -5.80 și kurtosis-ul ridicat de 39.20 indică o distribuție puternic asimetrică, cu valori extreme negative. Aceasta sugerează că majoritatea companiilor au cheltuieli mari în investiții, dar și câteva investiții pozitive semnificative, reflectând o etapă de expansiune și investiții care nu au adus încă randamente pe termen scurt.

**Variabila X9**, *fluxul de numerar din activitățile de finanțare*, prezintă o variație mare, cu valori între -120,188,000 și 15,861,000 USD, având o medie de -3,784,671 USD și o mediană de -333,922 USD. Coeficientul de asimetrie de -6.07 și kurtosis-ul de 41.95 sugerează o distribuție puternic asimetrică, cu o coadă extinsă pe partea stângă, indicând prezența unor valori extreme negative. Aceste valori extreme reflectă fluxuri de numerar semnificative, posibil asociate cu rambursări de datorii sau plăți financiare mari, în timp ce majoritatea companiilor sunt angajate în finanțări mai modeste sau acoperirea unor costuri financiare. Acest lucru poate semnala dificultăți financiare sau ajustări ale structurii financiare a firmelor, cu un număr mic de companii care beneficiază de finanțări pozitive (fluxuri de numerar din finanțare).

**Variabila X10**, *fluxul de numerar liber*, variază între -12,584,000 și 104,339,000 USD, cu o medie de 4,470,735 USD și o mediană de 547,864 USD. Coeficientul de asimetrie de 5.03 indică o distribuție puternic asimetrică spre dreapta, cu câteva companii generând fluxuri de numerar extrem de mari. Kurtosis-ul de 28.42 sugerează o concentrare mare a valorilor în jurul medianei, dar și câteva valori extreme. Din punct de vedere economic, fluxul de numerar liber reflectă sănătatea financiară a firmelor, indicând companii cu potențial de investiții sau recompensare a acționarilor. Aceasta distribuție sugerează că, în timp ce majoritatea firmelor au un flux de numerar mai modest, câteva dintre ele generează sume semnificative, ceea ce poate reflecta companii puternic capitalizate și cu oportunități de investiții sau de recompensare a acționarilor.

Analiza statistica a variabilelor sugerează o piață diversificată, dominată de câțiva jucători mari, cu performanțe financiare semnificativ diferite. Majoritatea companiilor au valori financiare de nivel mediu, dar există câteva companii extrem de profitabile, care influențează semnificativ media. Distribuțiile variabilelor reflectă o concentrare a valorilor în jurul medianei, cu valori extreme care subliniază volatilitatea pieței și diferențele mari între companii. Aceste tendințe indică o competiție neregulată, unde câțiva lideri domină și generează performanțe financiare mult mai mari decât majoritatea.

### **Matricea de corelatie si matricea de covarianta**

Pentru a observa mai bine rezultatele si a fi mai usor de interpretat, am standardizat datele utilizand functia scale.

	X1	X2	X3	X4	X5	X6	X7	X8	X9	X10
X1	1.0000000	0.8670451	0.7387270	0.6812634	0.7063487	0.1643344	0.8014608	-0.5710709	-0.6513095	0.6967598
X2	0.8670451	1.0000000	0.9315011	0.8774615	0.8981841	0.2130617	0.9254424	-0.5847136	-0.8305423	0.8784055
X3	0.7387270	0.9315011	1.0000000	0.9802713	0.9890902	0.2350240	0.9634615	-0.5722040	-0.9177854	0.9521347
X4	0.6812634	0.8774615	0.9802713	1.0000000	0.9959277	0.2637897	0.9405305	-0.5555917	-0.9155429	0.9189691
X5	0.7063487	0.8981841	0.9890902	0.9959277	1.0000000	0.2623389	0.9528331	-0.5736377	-0.9164993	0.9293093
X6	0.1643344	0.2130617	0.2350240	0.2637897	0.2623389	1.0000000	0.2323778	-0.2266891	-0.1800397	0.1780725
X7	0.8014608	0.9254424	0.9634615	0.9405305	0.9528331	0.2323778	1.0000000	-0.7093295	-0.8606511	0.9041020
X8	-0.5710709	-0.5847136	-0.5722040	-0.5555917	-0.5736377	-0.2266891	-0.7093295	1.0000000	0.3023155	-0.4130154
X9	-0.6513095	-0.8305423	-0.9177854	-0.9155429	-0.9164993	-0.1800397	-0.8606511	0.3023155	1.0000000	-0.9069794
X10	0.6967598	0.8784055	0.9521347	0.9189691	0.9293093	0.1780725	0.9041020	-0.4130154	-0.9069794	1.0000000

Figura 3. Matricea de corelatie

	X1	X2	X3	X4	X5	X6	X7	X8	X9	X10
X1	1.0000000	0.8670451	0.7387270	0.6812634	0.7063487	0.1643344	0.8014608	-0.5710709	-0.6513095	0.6967598
X2	0.8670451	1.0000000	0.9315011	0.8774615	0.8981841	0.2130617	0.9254424	-0.5847136	-0.8305423	0.8784055
X3	0.7387270	0.9315011	1.0000000	0.9802713	0.9890902	0.2350240	0.9634615	-0.5722040	-0.9177854	0.9521347
X4	0.6812634	0.8774615	0.9802713	1.0000000	0.9959277	0.2637897	0.9405305	-0.5555917	-0.9155429	0.9189691
X5	0.7063487	0.8981841	0.9890902	0.9959277	1.0000000	0.2623389	0.9528331	-0.5736377	-0.9164993	0.9293093
X6	0.1643344	0.2130617	0.2350240	0.2637897	0.2623389	1.0000000	0.2323778	-0.2266891	-0.1800397	0.1780725
X7	0.8014608	0.9254424	0.9634615	0.9405305	0.9528331	0.2323778	1.0000000	-0.7093295	-0.8606511	0.9041020
X8	-0.5710709	-0.5847136	-0.5722040	-0.5555917	-0.5736377	-0.2266891	-0.7093295	1.0000000	0.3023155	-0.4130154
X9	-0.6513095	-0.8305423	-0.9177854	-0.9155429	-0.9164993	-0.1800397	-0.8606511	0.3023155	1.0000000	-0.9069794
X10	0.6967598	0.8784055	0.9521347	0.9189691	0.9293093	0.1780725	0.9041020	-0.4130154	-0.9069794	1.0000000

Figura 4. Matricea de covarianta

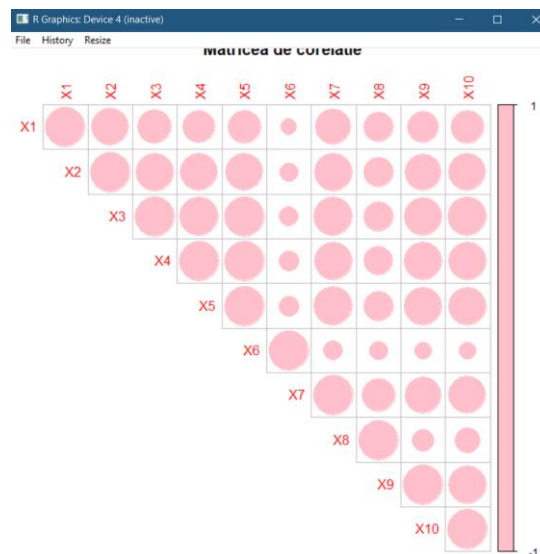


Figura 5. Reprezentarea grafica a matricei de corelație

Analizând matricea de corelație, putem observa că majoritatea variabilelor financiare sunt puternic (pozitiv) corelate între ele. Acest lucru sugerează că există o relație directă între veniturile și performanțele financiare ale companiilor. Cu toate acestea, se remarcă faptul că toate variabilele au corelații negative cu variabilele X8 și X9, reprezentând fluxul de numerar din activități de investiții și fluxul de numerar din activități de finanțare. Aceste corelații negative sugerează că, pe măsura ce cresc cheltuielile cu investițiile și datoriile externe, performanța financiară a companiei este afectată negativ, aceste fluxuri putând reduce profitabilitatea și lichiditatea, indicând o presiune financiară suplimentară pe termen scurt, în ciuda potențialului de creștere pe termen lung.

În ceea ce privește variabila X6, venitul pe acțiune (EPS), corelațiile sale cu celelalte variabile financiare sunt relativ scăzute, indicând o relație slabă între performanța pe acțiune a companiilor și ceilalți indicatori financiare. Acest lucru poate sugera că venitul pe acțiune nu este direct influențat de variabilele macroeconomice, reflectând mai mult performanța individuală a companiilor în raport cu așteptările pieței.

Observăm că după standardizarea datelor, matricea de covarianță este egală cu matricea de corelație, toate variabilele având aceeași deviație standard (1) și media 0, ceea ce le face comparabile direct între ele. Astfel, valorile observate reflectă doar relațiile dintre variabile, fără influența unității de măsură, astfel încât covarianțele și corelațiile devin mai ușor de interpretat.

Valorile matricei de covarianță oferă informații despre modul în care variabilele economice analizate variază în raport una cu cealaltă. Analizând această matrice, putem observa că valoarea covarianței dintre majoritatea variabilelor financiare este pozitivă, ceea ce înseamnă că între variabile există o relație directă, pe măsura ce una dintre variabile crește, cealaltă tinde să crească și ea. De exemplu, covarianța dintre X1 (Venit total) și X2 (Profit brut) este 0.867, ceea

ce sugerează o relație puternic pozitivă. Așadar, atunci când venitul total al unei firme crește, profitul brut tinde să crească și el, ceea ce este un semn de performanță economică solidă. Acesta este un indiciu că aceste variabile evoluează simultan în direcția pozitivă și sunt corelate în mod direct. Pe de altă parte, între X8 (fluxul de numerar din activități de investiții) și X9 (fluxul de numerar din activități de finanțare) și restul variabilelor financiare, există corelații negative. Acest lucru sugerează că, pe măsură ce fluxurile din investiții sau finanțare cresc, celelalte variabile financiare (de exemplu, venitul total, profitul brut) tind să scadă. Aceasta poate indica faptul că investițiile și finanțările externe sunt invers proporționale cu profitabilitatea și stabilitatea pe termen scurt, deoarece resursele financiare sunt alocate pe termen lung, ceea ce afectează fluxurile de numerar din operațiuni și alte activități economice.

### **Reprezentari grafice**

**Histogramele si densitatile de probabilitate ale variabilelor X1(Venit total generat), X2(Profitul brut) si X6(Venitul pe acțiune):**

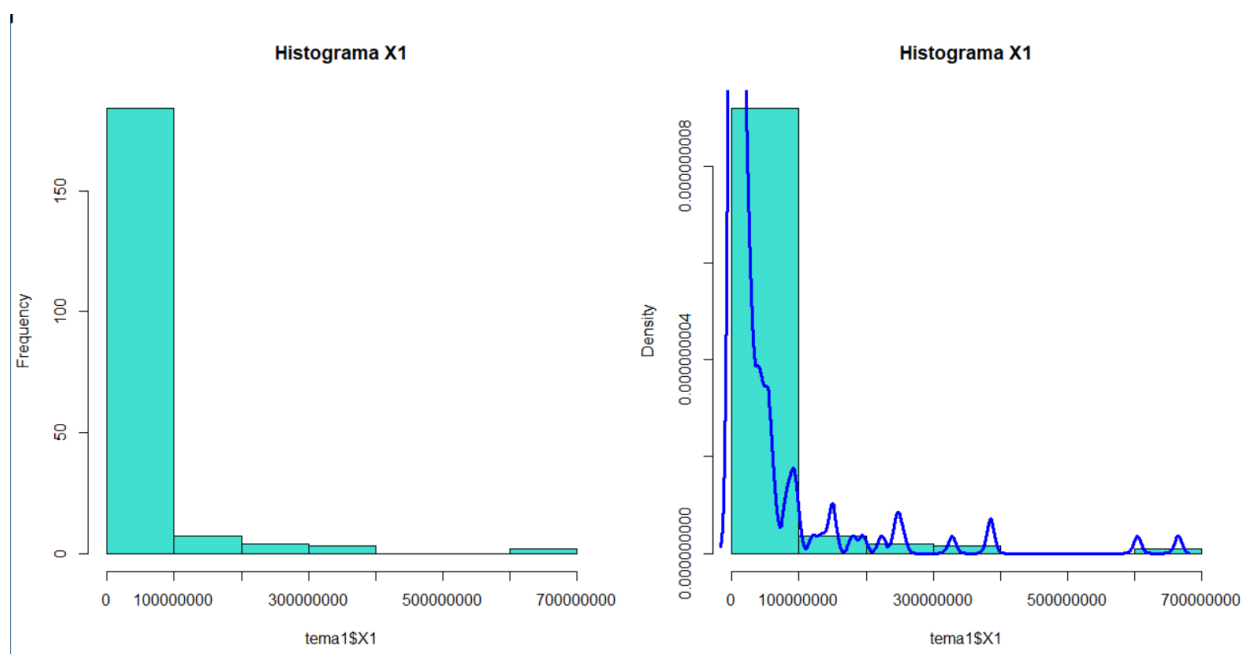


Figura 6. Histograma si densitatea de probabilitate ale variabilei X1



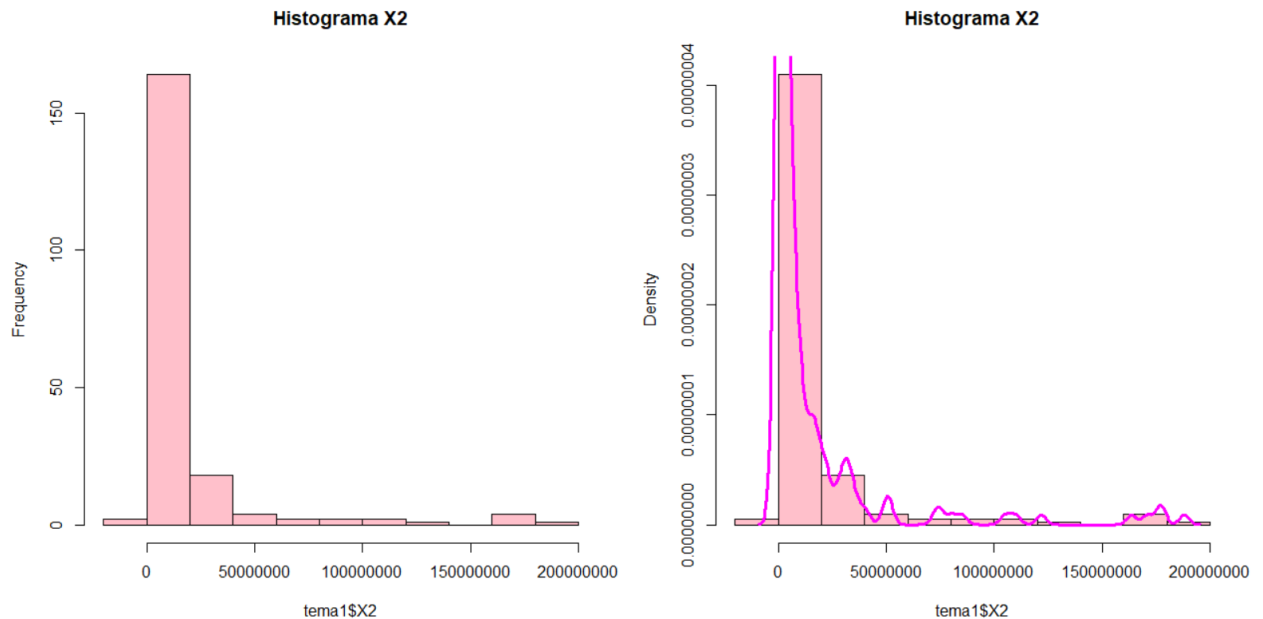


Figura 7. Histograma si densitatea de probabilitate ale variabilei X2

Cu ajutorul acestor reprezentari grafice putem observa faptul ca distributiile celor doua variabile sunt puternic asimetrice la dreapta si leptocurtice, majoritatea companiilor avand valori moderate pentru venitul total si profitul brut, insa exista si cateva valori extreme reprezentate de companiile mai mari si mai profitabile ce domina piata bursiera, aflate in partea dreapta a histogramelor, si influentand forma distributiei.

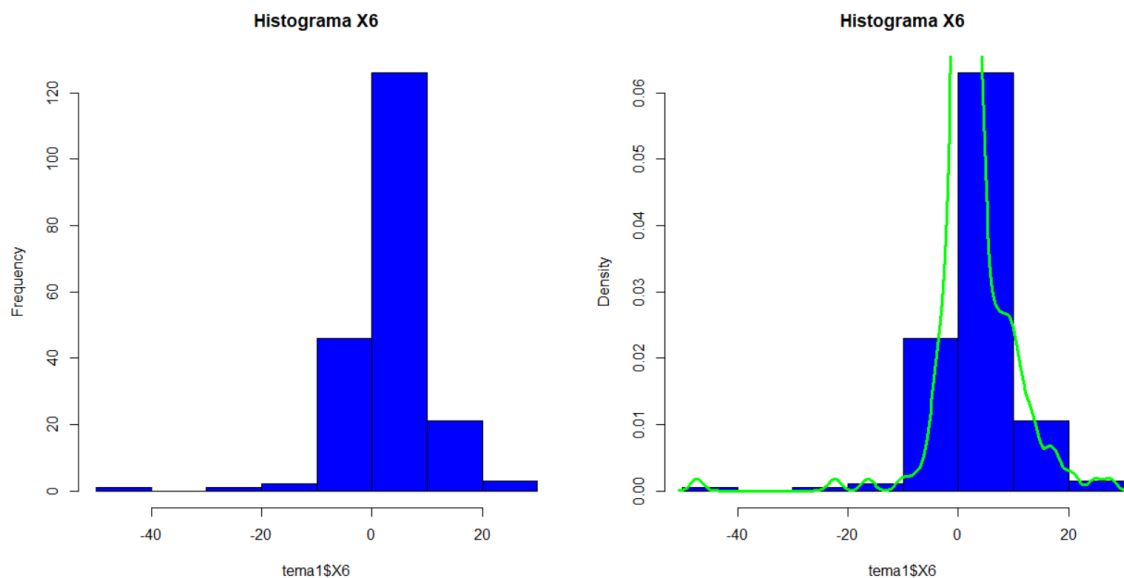


Figura 8. Histograma si densitatea de probabilitate ale variabilei X6

Analizand cele doua grafice din figura 8, putem determina faptul ca variabila X6 (Venit pe actiune - EPS) prezinta o distributie asimetrica spre stanga, in care majoritatea valorilor sunt concentrate în partea dreaptă, cu o coadă mai lungă în stânga, ceea ce poate reflecta un număr semnificativ de companii cu pierderi sau valori mici ale EPS. De asemenea, distributia este leptocurtica, avand o concentratie mare de valori in jurul mediei si cativa outlieri.

### Dependenta dintre 2 variabile. Dreapta de regresie (pentru X1 si X2):




Figura 9. Dreapta de regresie dintre X1 si X2

X1 reprezintă variabila independentă, iar X2 este variabila dependentă. Analizând graficul scatter plot de mai sus, observăm că la început datele urmează o relație liniară, ceea ce sugerează că pentru anumite valori ale lui X1 și X2, rezultatele pot fi aproximativ prezise folosind o dreaptă de regresie. Totuși, pe măsură ce valorile cresc, relația devine mai complexă, iar previziunea devine mai dificilă. X1 explică doar parțial variabilitatea lui X2, existând și alți factori care devin mai relevanți pe măsură ce datele se dezvoltă. De asemenea, putem observa prezența valorilor extreme sau a outlierilor, reprezentate de punctele care se îndepărtează semnificativ de dreapta de regresie, ce reprezintă companiile mari cu valori neobișnuite.




Figura 10. Scatter plot

Analizand figura 10, putem determina companiile cele mai profitabile, ce domina piata bursiera, avand veniturile si profiturile semnificativ mai mari decat ale celorlalte companii. Cateva dintre acestea sunt GOOG (Google Alphabet Inc.), APPL(Apple Inc.), AMZN(Amazon.com Inc.), WMT(Walmart Inc.), MSFT(Microsoft Corp.), META(Meta Platforms, Inc.), ERIC(Ericsson AB), etc.

### Boxplot pentru X1, X2 si X6:

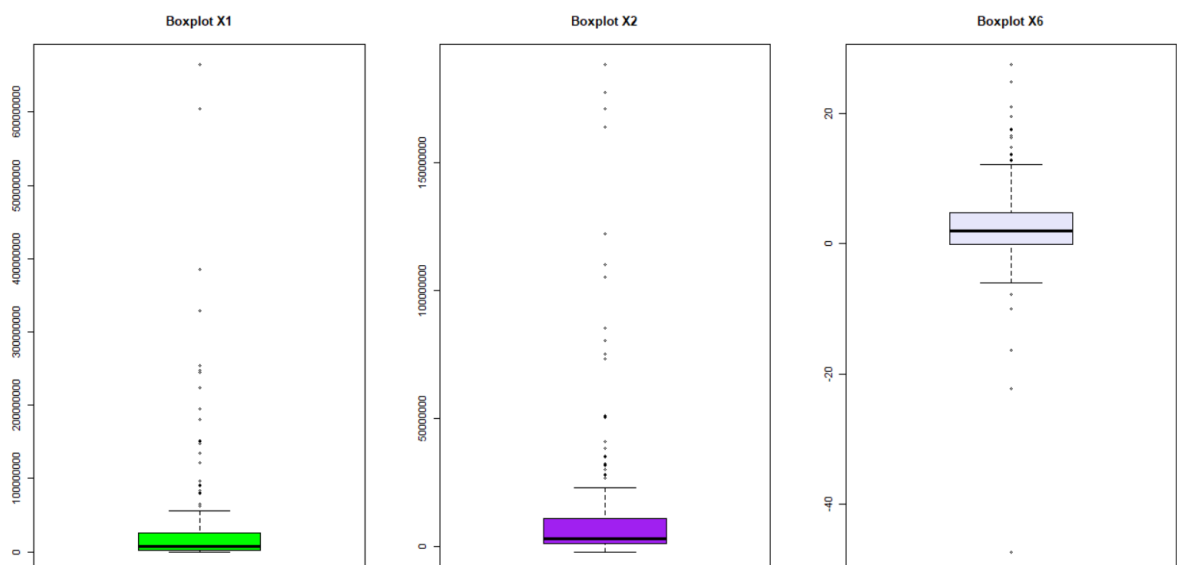


Figura 11. Graficele boxplot pentru variabilele X1, X2 si X6

Pe baza figurii, observam ca distributiile celor doua variabile (X1, respectiv X2) sunt puternic asimetrice la dreapta, majoritatea valorilor fiind concentrate in partea inferioara a graficului (valori mici), si prezentand foarte multe valori extreme/outliere. Cu toate ca outlierii influenteaza semnificativ rezultatele, acestia sunt reprezentativi pentru fenomenul analizat, oferind informatii valoroase despre companiile ce domina piata. Valorile venitului total (X1) se situeaza sub 100M USD pentru majoritatea companiilor analizate, fiind prezente si valori extreme ce depasesc 100M USD, ajungand chiar la 500M USD. Iar in cazul profitului brut (X2), majoritatea valorilor se situeaza sub 50M, existand si valori extreme ce ajung pana la 150M USD. In ceea ce priveste variabila X6, boxplotul confirma asimetria spre stanga a distributiei, evidentiata de concentrarea majoritatii valorilor in partea dreapta si o coada mai lunga in stanga, care sugereaza existenta mai multor companii cu EPS scazut/negativ.

### **Metoda ACP**

Ca un prim pas in analiza componentelor principale (ACP), am analizat matricea de corelatie si am ales sa elimin variabilele X6, X8 si X9, deoarece X8 si X9 au corelatii negative cu toate celelalte variabile, iar X6 are, de asemenea, relatii de corelatie slaba cu celelalte variabile, acestea fiind mai putin relevante pentru explicatia variabilitatii totale a datelor. Eliminarea acestora ajuta la imbunatatirea calitatii analizei, concentrandu-se pe variabilele care au o corelatie mai puternica cu celelalte, si, de asemenea, reduce dimensiunea datelor, facilitand interpretarea si identificarea principalilor factori care influenteaza variabilitatea setului de date.

Apoi, am standardizat noul set de date si am determinat componentele principale.

```
> analizacp = princomp(date_std, cor=T)
> analizacp
Call:
princomp(x = date_std, cor = T)

Standard deviations:
      Comp.1      Comp.2      Comp.3      Comp.4      Comp.5      Comp.6
2.51262481 0.68053306 0.32479883 0.25273320 0.21366865 0.07870759
      Comp.7
0.04872139

7 variables and 200 observations.
```

Figura 12. Determinarea componentelor principale

Pe baza acestora, am calculat abaterea standard, valorile proprii, procentul informational si procentul cumulat, pe care le-am introdus intr-un nou data frame.

	sdev	valp	procent_info	procent_cumulat
<b>Comp.1</b>	2.51262481	6.313283455	90.18976365	90.18976
<b>Comp.2</b>	0.68053306	0.463125242	6.61607489	96.80584
<b>Comp.3</b>	0.32479883	0.105494279	1.50706112	98.31290
<b>Comp.4</b>	0.25273320	0.063874072	0.91248675	99.22539
<b>Comp.5</b>	0.21366865	0.045654292	0.65220417	99.87759
<b>Comp.6</b>	0.07870759	0.006194885	0.08849836	99.96609
<b>Comp.7</b>	0.04872139	0.002373774	0.03391106	100.00000

Figura 13. Data frame ACP

### ***Aplicarea celor 3 criterii de alegere a numarului de componente principale***

#### **Criteriul 1 – Screeplot**

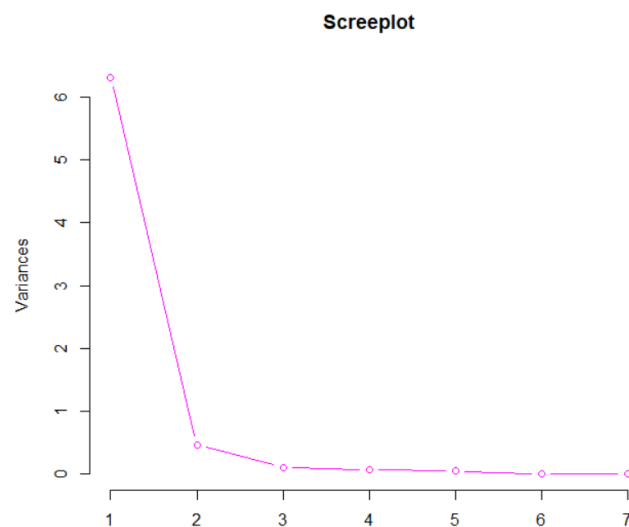


Figura 14. Screeplot

Pe axa orizontală sunt plasate componentele principale, iar pe axa verticală se regăsesc valorile proprii (sau varianța).

Acest screeplot este utilizat pentru a stabili, ca prim criteriu, numărul optim de componente principale. Trasând o linie orizontală de la punctul de cotitură (unde panta începe să se apropie de valoarea 0), în această analiză, numărul de componente păstrate este determinat de

primul întreg la stânga acelei drepte. În cazul nostru, acest număr este 1, indicând faptul că doar prima componentă principală ar trebui păstrată în analiza.

### Criteriul lui Kaiser

Conform criteriului lui Kaiser, vom păstra în analiză componentele principale cu valori proprii mai mari sau egale cu 1. Analizând figura 13, observăm că doar Componenta 1 are o valoare proprie mai mare de 1, având valoarea de 6.31. Prin urmare, aplicând acest criteriu, vom reține în analiză doar o singură componentă principală.

### Criteriul procentului de acoperire (procentului cumulat)

Conform acestui criteriu, procentul de acoperire ar trebui să fie între 70-80%. Totuși, analizând figura 13, observăm că procentul cumulat al primei componente este de 90.18%, ceea ce sugerează că o singură componentă explică o mare parte din variabilitatea datelor, acoperind aproximativ 90% din varianta totală. Astfel, aceasta capturează o parte semnificativă din structura datelor. Prin urmare, pierderea informațională va fi de  $100\% - 90.18\% = 9.82\%$ .

În urma analizei celor trei criterii, vom păstra în analiză doar o singură componentă principală.

### **Calcularea vectorilor proprii și a formei generale pentru componenta principală**

```
> print(analizacp$loadings, cutoff = 0.0001)
```

Loadings:

	Comp.1	Comp.2	Comp.3	Comp.4	Comp.5	Comp.6	Comp.7
X1	0.326	0.826	0.028	0.375	0.253	0.069	0.015
X2	0.382	0.267	-0.121	-0.844	-0.033	-0.235	-0.024
X3	0.394	-0.183	0.011	-0.124	0.026	0.839	0.302
X4	0.385	-0.311	0.337	0.119	0.393	-0.438	0.531
X5	0.389	-0.262	0.270	0.054	0.278	0.041	-0.791
X7	0.389	0.011	0.297	0.206	-0.837	-0.129	0.003
X10	0.377	-0.218	-0.842	0.270	-0.036	-0.160	-0.032

	Comp.1	Comp.2	Comp.3	Comp.4	Comp.5	Comp.6	Comp.7
SS loadings	1.000	1.000	1.000	1.000	1.000	1.000	1.000
Proportion Var	0.143	0.143	0.143	0.143	0.143	0.143	0.143
Cumulative Var	0.143	0.286	0.429	0.571	0.714	0.857	1.000

Figura 15. Vectorii proprii

Forma generala a componentei principale (Comp. 1):

$$W1 = 0.326 * X1 + 0.382 * X2 + 0.394 * X3 + 0.385 * X4 + 0.389 * X5 + 0.389 * X7 + 0.377 * X10$$

X10

### Calcularea scorurilor pentru componenta principala

	V1
GOOG	12.77177301
META	7.82244210
RDDT	-0.98289333
SPOT	-0.82908116
NVDA	6.45699904
SNAP	-0.98119157
TSLA	0.69355668
SMCI	-0.90337207
AMD	-0.58524903
DJT	-0.95867833
PFE	-0.15855041
F	0.60344748
AMZN	9.59208383
INTC	-0.53099872
CMG	-0.69353616
SOUN	-0.96505168
APPL	15.51962950
LLY	0.25360036

Figura 16. Scorurile principale pentru Comp. 1

### Calcularea si reprezentarea grafica a matricei factor

Matricea factor reprezinta matricea de corelatie dintre variabilele originale si componentele principale.

	V1
X1	0.8196284
X2	0.9589688
X3	0.9894042
X4	0.9661918
X5	0.9774429
X7	0.9776544
X10	0.9477455

Figura 17. Matricea factor




Figura 18. Reprezentarea grafica a matricei factor

Putem observa faptul ca componenta principala se coreleaza puternic cu toate celelalte variabile, de aceea aceasta componenta explica varianta datelor intr-o mare masura. Avand in vedere corelatiile puternice cu variabilele originale, aceasta poate fi denumita PERFORMANTA FINANCIARA, deoarece capteaza aspecte esentiale legate de profitabilitatea si lichiditatea companiilor, fiind influentata de veniturile si fluxurile de numerar care reflecta sanatatea financiara.

### **Cercul corelatiilor**




Figura 19. Cercul corelatiilor

Pe baza cercului corelatiilor, putem determina relatiile de corelatie dintre variabile, unghiul dintre vectori indicand acest lucru. Analizand figura 19, observam ca toate variabilele au unghiuri mai mici de 90 de grade, ceea ce inseamna ca au relatii de corelatie puternica cu componenta principala.



## Reprezentarea scorurilor principale pentru diadele de componente principale

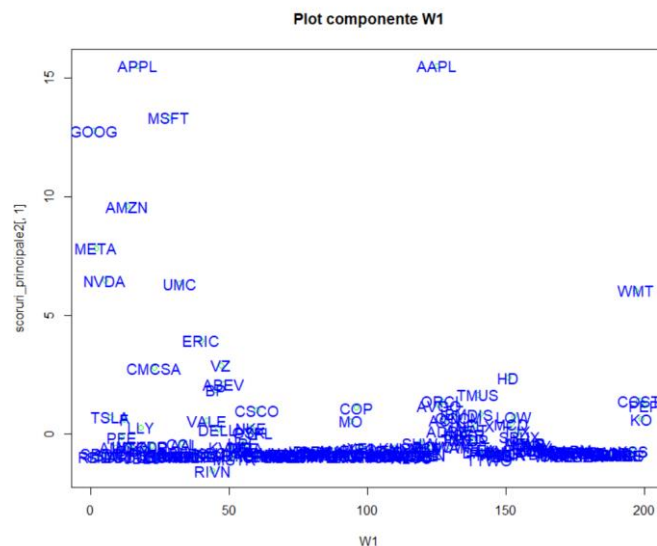


Figura 20. Reprezentarea scorurilor principale

Pe baza acestei reprezentări, putem observa pozițiile diverselor companii și putem identifica asemănările și diferențele dintre ele. De exemplu, companiile apropiate, precum AAPL, MSFT și GOOG, au profiluri similare, în timp ce companiile mai îndepărtate, cum ar fi AAPL și WMT, prezintă diferențe semnificative. De asemenea, se pot observa clustere în partea inferioară a graficului, unde sunt situate majoritatea observațiilor, și outliere cu valori neobișnuite, aflate în partea superioară a graficului.

## **Biplot**

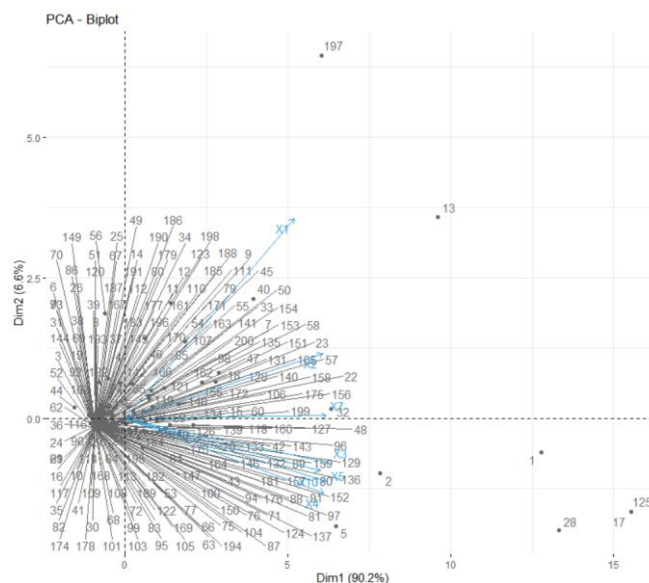


Figura 21. Graficul biplot

Graficul biplot oferă informații atât despre variabile, cât și despre observații. În ceea ce privește variabilele, lungimea săgeților indică influența fiecărei variabile asupra componentei principale – cu cât săgeata este mai lungă, cu atât variabila contribuie mai mult. Astfel, observăm că variabilele X1 (Venitul total), X3 (Venitul operațional) și X5 (Profitul înainte de dobânzi și taxe) au cea mai mare influență asupra componentei principale. În ceea ce privește observațiile, cele situate aproape unele de altele au profiluri financiare similare și formează un cluster în zona centrală a axelor. Pe de altă parte, observațiile mai departate de centru, care se află la marginea graficului, reprezintă outliere, indicând diferențe semnificative în performanța financiară.

## Calculul contributiilor variabilelor si observatiilor, precum si calitatea reprezentarii pentru variabile si indivizi

```
Call:
PCA(X = date_std)
```

Eigenvalues

	Dim.1	Dim.2	Dim.3	Dim.4	Dim.5	Dim.6	Dim.7
Variance	6.313	0.463	0.105	0.064	0.046	0.006	0.002
% of var.	90.190	6.616	1.507	0.912	0.652	0.088	0.034
Cumulative % of var.	90.190	96.806	98.313	99.225	99.878	99.966	100.000

Individuals (the 10 first)

	Dist	Dim.1	ctr	cos2	Dim.2	ctr	cos2	Dim.3	ctr	cos2
1	12.849	12.772	12.919	0.988	-0.599	0.387	0.002	-0.840	3.345	0.004
2	7.952	7.822	4.846	0.968	-0.970	1.015	0.015	0.130	0.080	0.000
3	0.991	-0.983	0.077	0.983	-0.122	0.016	0.015	0.019	0.002	0.000
4	0.832	-0.829	0.054	0.994	-0.011	0.000	0.000	0.042	0.008	0.003
5	6.755	6.457	3.302	0.914	-1.913	3.949	0.080	0.195	0.180	0.001
6	0.985	-0.981	0.076	0.993	-0.044	0.002	0.002	0.042	0.008	0.002
7	0.981	0.694	0.038	0.500	0.395	0.168	0.162	-0.389	0.717	0.157
8	0.947	-0.903	0.065	0.910	-0.024	0.001	0.001	-0.163	0.126	0.030
9	0.606	-0.585	0.027	0.933	0.077	0.006	0.016	0.033	0.005	0.003
10	0.974	-0.959	0.073	0.969	-0.164	0.029	0.028	-0.007	0.000	0.000

Variables

	Dim.1	ctr	cos2	Dim.2	ctr	cos2	Dim.3	ctr	cos2
X1	0.820	10.641	0.672	0.562	68.268	0.316	-0.009	0.076	0.000
X2	0.959	14.566	0.920	0.182	7.121	0.033	0.039	1.472	0.002
X3	0.989	15.506	0.979	-0.124	3.340	0.015	-0.004	0.013	0.000
X4	0.966	14.787	0.934	-0.211	9.648	0.045	-0.109	11.365	0.012
X5	0.977	15.133	0.955	-0.178	6.841	0.032	-0.088	7.308	0.008
X7	0.978	15.140	0.956	0.007	0.011	0.000	-0.097	8.841	0.009
X10	0.948	14.227	0.898	-0.149	4.770	0.022	0.274	70.925	0.075

Figura 22. Contributia si calitatea reprezentarii pentru variabile si indivizi

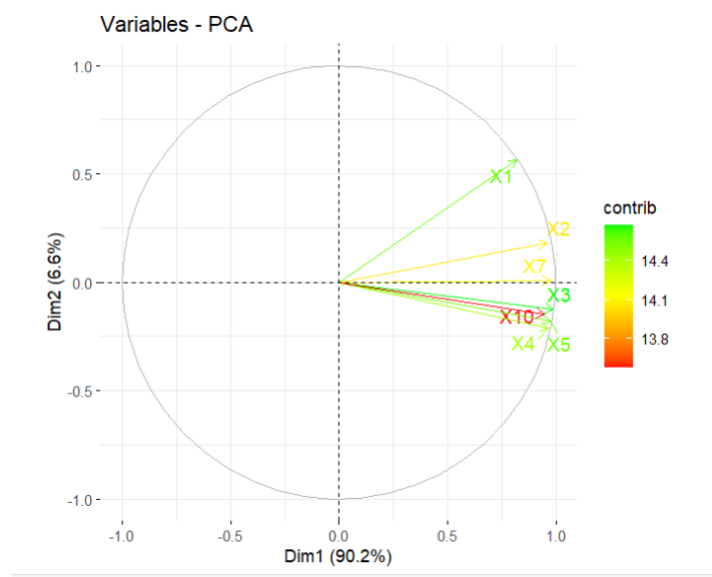


Figura 23. Contributiile variabilelor




Figura 24. Calitatea reprezentării variabilelor

Analizand figurile de mai sus, se observă că variabilele cu cea mai mare contribuție la definirea componentei principale sunt X3 - Venitul operational, X5 - EBIT și X4 – Venitul net. Asadar, componenta principala capteaza mai ales informatia adusa de aceste variabile, acestea avand o valoare semnificativa in definirea componentei. În ceea ce privește calitatea reprezentării, variabilele cel mai bine reprezentate în componenta principală sunt tot X3, X5 și X4, valorile ridicate ale acestora (foarte apropiate de 1) indicand o reprezentare buna pe componenta principala.

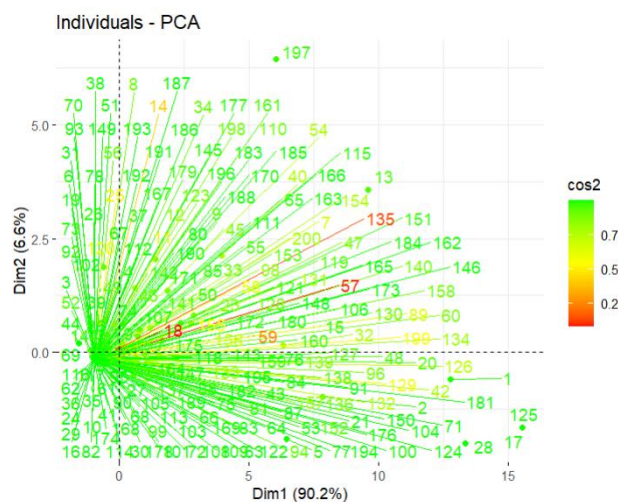


Figura 25. Calitatea reprezentării observațiilor




Figura 26. Contribuțiile observațiilor

Analizând graficele, observăm că majoritatea observațiilor au o calitate ridicată a reprezentării, având valori mari pentru  $\cos^2$ , ceea ce sugerează că variabilele din componenta 1 le descriu destul de bine. Totuși, există câteva observații cu o calitate moderată și chiar unele cu o reprezentare slabă (precum observațiile 18, 57 și 135), indicând faptul că variabilele ce contribuie la componenta principală nu reușesc să le descrie suficient de bine. În ceea ce privește contribuția observațiilor la componentele principale, majoritatea acestora au o contribuție scăzută, ceea ce sugerează că aceste observații nu influențează semnificativ structura generală a datelor. Astfel, este posibil ca aceste observații să fie mai puțin relevante în contextul componentei principale.

## **Concluzii**

În urma analizei setului de date prin intermediul metodei ACP, se evidențiază faptul că prima componentă principală captează majoritatea informațiilor esențiale despre performanța financiară a companiilor, fiind influențată în mod semnificativ de variabile precum Venitul Operațional (X3), EBIT (X5) și Venitul Net (X4). Acestea sunt cele mai relevante în definirea structurii datelor și explică o mare parte din variabilitatea acestora (90.18%). Observăm, de asemenea, că majoritatea companiilor formează clustere, având profile financiare similare. Totuși, există un număr de companii cu performanțe financiare extreme, care deviază semnificativ de la tendințele generale și pot influența puternic analiza, fiind considerate outlieri. Aceste companii sunt esențiale în analiza pieței, deoarece domină într-o măsură semnificativă indicatorii financiar.

Prin urmare, analiza sugerează că performanța financiară a companiilor este puternic influențată de factori precum venitul operațional, profitul brut și venitul net, ceea ce subliniază importanța fluxurilor de numerar și a gestionării eficiente a resurselor în asigurarea unei stabilități financiare pe termen lung. Companiile cu valori extreme pot domina piețele și pot reprezenta surse de inovație sau schimbare structurală. În același timp, companiile cu performanțe financiare moderate/similare formează un sector relativ stabil, unde strategiile economice și financiare standard pot fi mai ușor implementate.

## ANEXA

```
tema1 <- Date_AD
View(tema1)
#Calcularea indicatorilor statistici
summary(tema1)
install.packages("psych")
library(psych)
describe(tema1[-1])
#Matricea de corelatie si de covarianta
cor(tema1[-1])
cov(tema1[-1])
#Pentru a observa mai bine rezultatele, vom standardiza datele
tema1_std = scale(tema1[-1], scale = T)
View(tema1_std)
#Recalculam corelatia si covarianta
matrice_corelatie <- cor(tema1_std)
matrice_covarianta <- cov(tema1_std)
#Reprezentarea grafica a matricei de corelatie

install.packages("corrplot")
library(corrplot)
?corrplot
windows()
corrplot(matrice_corelatie, method = "circle", type = "upper", col = "pink", title =
"Matricea de corelatie" )
```

Iordan Maria-Alexandra  
Grupa 1080-A

```
#Reprezentari grafice

options(scipen=999) #afisarea numerelor intr-un format standard fara exponent
windows()

par(mfrow=c(1,2)) #afisarea graficelor in aceeași fereastră

#Distributia variabilei X1 - histograma
hist(tema1$X1, col = "turquoise", main = "Histograma X1")

#Densitatea de probabilitate
# Aduagam freq = F
hist(tema1$X1, col = "turquoise", main = "Histograma X1", freq = F)
lines(density(tema1$X1), col="blue", lwd=3)

#Distributia variabilei X2 - histograma
hist(tema1$X2, col = "pink", main = "Histograma X2")

#Densitatea de probabilitate
# Aduagam freq = F
hist(tema1$X2, col = "pink", main = "Histograma X2", freq = F)
lines(density(tema1$X2), col="magenta", lwd=3)

#Distributia variabilei X6 - histograma
hist(tema1$X6, col = "blue", main = "Histograma X6")

#Densitatea de probabilitate
# Aduagam freq = F
hist(tema1$X6, col = "blue", main = "Histograma X6", freq = F)
lines(density(tema1$X6), col="green", lwd=3)


#Dependenta dintre 2 variabile -> regresia
plot(tema1$X1, tema1$X2, col="black")
abline(lm(tema1$X2~tema1$X1), col="purple")

#scatter plot
install.packages("ggplot2")
```



Iordan Maria-Alexandra  
Grupa 1080-A

```
library(ggplot2)
ggplot(tema1, aes(x=X1, y=X2))+
  geom_point()+
  geom_text(label=tema1$Companie, color="magenta",
            nudge_x = 0.25, nudge_y = 0.25,
            check_overlap = T)
par(mfrow=c(1,3))
```

```
#Boxplot
```

```
boxplot(tema1$X1, col="green", main="Boxplot X1")
boxplot(tema1$X2, col="purple", main="Boxplot X2")
boxplot(tema1$X6, col="lavender", main="Boxplot X6")
```

```
#Metoda ACP
```

```
View(tema1)
```

```
cor(tema1[-1])
```

#Observam ca X8 si X9 au corelatii negative cu majoritatea variabilelor, iar X6 are relatii de corelatie slaba cu celelalte variabile, asadar le voi elimina pe acestea din analiza pentru a simplifica modelul

```
date_acp <- cbind(tema1[,2:6], tema1[,8], tema1[,11])
```

```
View(date_acp)
```

```
date_std = scale(date_acp, scale = T)
```

```
View(date_std)
```

```
analizacp = princomp(date_std, cor=T)
```

```
analizacp
```

```
sdev = analizacp$sdev
```

```
valp = sdev*sdev
```

```
procent_info = (valp/sum(valp))*100
```

```
procent_cumulat=cumsum(procent_info)
```

```
ACP = data.frame(sdev, valp, procent_info, procent_cumulat)
```

Iordan Maria-Alexandra  
Grupa 1080-A

ACP

View(ACP)

#Cele 3 criterii de alegere a nr de componente principale

#Criteriul 1 - Screeplot

windows()

screeplot = prcomp(date\_std)

plot(screeplot, type = "l", main = "Screeplot", col = "magenta")

#Pe axa orizontala avem componentele principale, iar pe axa verticala avem varianta/valorile proprii

#Acest screeplot il folosim ca un prim criteriu pt alegerea unui nr potrivit de comp principale

#Prima data ducem o dreapta paralela cu axa verticala din punctul de cotitura (2) -repr punctul in care panta incepe sa se apropie de 0 - si primul intreg din stanga drepteii va repr nr de componente pe care le pastram

#O singura componenta principala

#Criteriul lui Kaiser - vom retine in analiza componentele principale care au valorile proprii mai mari sau egale cu 1

#Observam ca valp este  $\geq 1$  doar pentru prima componenta

#o componenta principala

#Criteriului procentului de acoperire - procent cumulat

#Cu toate ca ar trebui sa avem un procent de acoperire in jur de 70-75-80%, procentul cumulat al primei componente este de 90.18% (procentul cumulat minim), aratand ca o singura componenta explica suficient de mult varianta datelor, acoperind aproximativ 90% din varianta totala, inseamna ca aceasta captureaza o parte semnificativa din structura datelor

#Pierdere informatională:  $100 - 90.18 = 9.82\%$

#Pastram in analiza o componenta principala

a = analizacp\$loadings

a

#Pe coloane se regasesc vectorii proprii

print(analizacp\$loadings, cutoff = 0.0001)

Iordan Maria-Alexandra  
Grupa 1080-A

```
#Forma generala a componentei principale

#  $W1 = 0.326 * X1 + 0.382 * X2 + 0.394 * X3 + 0.385 * X4 + 0.389 * X5 + 0.389 * X7 + 0.377 * X10$ 

#Scorurile principale -inlocuim datele std in forma generala
scoruri_principale = matrix(analizacp$scores[,1], ncol = 1)
scoruri_principale
rownames(scoruri_principale) = tema1$Companie
scoruri_principale

#matricea factor - matricea de corelatie dintre variabilele originale si componentele principale
matrice_factor = cor(date_std, scoruri_principale)
matrice_factor
library(corrplot)
windows()
corrplot(matrice_factor, method = "number")

#Putem observa faptul ca componenta principala se coreleaza puternic cu toate celelalte variabile, de aceea aceasta componenta explica varianta datelor intr-o mare masura

#Avand in vedere corelatiile puternice cu variabilele originale, poate fi denumita PERFORMANTA FINANCIARA, deoarece capteaza aspecte esentiale legate de profitabilitatea si lichiditatea companiilor, fiind influentata de veniturile si fluxurile de numerar ce reflecta sanatatea financiara.

#Cercul corelatiilor
install.packages("FactoMineR")
library(FactoMineR)

windows()
cp = PCA(date_std)

#Reprezentarea scorurilor principale pentru diadele de componente principale
windows()
scoruri_principale2= data.frame(scoruri_principale)
```

Iordan Maria-Alexandra  
Grupa 1080-A

```
plot(scoruri_principale2[,1], main = "Plot componente W1", col="green", xlab="W1")
text(scoruri_principale2[,1], labels=rownames(scoruri_principale2), col="blue", cex=1.2)

#Biplot

install.packages("factoextra")
library(factoextra)

fviz_pca_biplot(analizacp, repel=TRUE,
                col.var="#2E9FDF", #Variables color
                col.ind="#696969" #Individuals color
)

#Contributia si calitatea reprezentarii pentru variabile si indivizi

cp
summary(cp)

#Contributiile variabilelor

fviz_pca_var(analizacp, col.var="contrib",
             gradient.cols=c("red", "yellow", "green"),
             repel=TRUE)

#Calitatea reprezentarii variabilelor

fviz_pca_var(analizacp, col.var="cos2",
             gradient.cols=c("red", "yellow", "green"),
             repel=TRUE)

#Calitatea reprezentarii observatiilor

fviz_pca_ind(analizacp, col.ind="cos2",
             gradient.cols=c("red", "yellow", "green"),
             repel=TRUE)

#Contributiile observatiilor

fviz_pca_ind(analizacp, col.ind="contrib",
             gradient.cols=c("red", "yellow", "green"),
             repel=TRUE)
```

Iordan Maria-Alexandra  
Grupa 1080-A